Clasificación de MRI con Redes Neuronales Convolucionales para Tipos de Cáncer

Diego Burbano Omar Diaz

1. Introducción

En el contexto de diagnóstico clínico a partir de la lectura de imágenes de resonancia magnética las instituciones médicas se encuentran en la necesidad de mejorar la precisión y la eficiencia diagnóstica en patologías complejas como los tumores cerebrales.

Hoy el desafío es mantener estándares de calidad, precisión y productividad en la lectura de imágenes MRI. Los errores humanos o diagnósticos tardíos de cáncer cerebral pueden generar graves consecuencias clínicas, incluyendo retrasos en el tratamiento, aumento de la morbilidad, y deterioro de la calidad de vida del paciente. Además, estos errores conllevan impactos administrativos y financieros, relacionados con reprocesos, controles de calidad, y litigios por responsabilidad.

Este informe desarrolla un modelo basado en redes neuronales convolucionales (CNN) para el diagnóstico de pacientes con cáncer cerebral que busca brindar apoyo a los profesionales de la salud en el diagnóstico preciso. De manera complementaria, se discuten las limitaciones que han restringido su adopción generalizada, y se propone una reflexión sobre los campos de implementación de la misma.

Para ello, construimos una arquitectura CNN estándar (*from scratch*) y una aproximación experimental basada en modelos fundacionales del tipo ResNet, bajo el *framework* MONAI (*Medical Open Network for AI*) [1], el cual es un consorcio de código abierto impulsado por profesionales de la salud (King's College London), desarrolladores, investigadores y empresas de tecnología (NVIDIA) y farmacéuticas de todo el mundo. Lo anterior, con el propósito de comparar sus resultados, ventajas y limitaciones en el marco del diagnóstico clínico.

2. Metodología

Para el desarrollo de los modelos citados, hemos utilizado el set de datos Brain Tumor MRI Dataset tomado del sitio kaggle.com [2] consistente en 7023 imágenes etiquetadas, sobre las cuales se realizaron un conjunto de transformaciones incluyendo su conversión a escalas de grises.

La fig. 1 resume la arquitectura general utilizada en la construcción de una Red Neuronal Convolucional (CNN) inspirada en *AlexNet*, adaptada para imágenes MRI en escala de grises. Consta de un bloque convolucional para la extracción jerárquica de características espaciales (bordes, texturas y patrones estructurales), seguido por capas totalmente conectadas (MLP) que realizan la clasificación final en cuatro categorías.

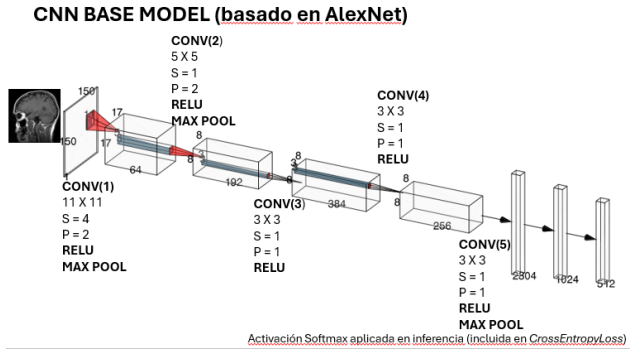

Fig 1. Figura que representa la arquitectura general de la red neuronal convolucional (CNN) basada en *AlexNet*.

Para la transformación de los datos, además de la conversión a un único canal, se implementó un *pipeline* de preprocesamiento que incluye la homogeneización del tamaño de las imágenes, la aplicación de rotaciones aleatorias para aumentar la variabilidad del conjunto, la conversión a tensores y el escalado de los valores de píxel al rango [−1,1] entre otras transformaciones.

El modelo implementado corresponde a una CNN profunda, adaptada para imágenes en escala de grises de 150×150 píxeles, resolución escogida para facilitar el alto procesamiento requerido. La arquitectura consta de un encoder con cinco capas convolucionales y tres operaciones de *max pooling* para la extracción jerárquica de características, todas con activación *ReLU*, y un *decoder* formado por tres capas totalmente conectadas (4096, 4096 y 4 neuronas, respectivamente) con *Dropout* (0.4) para reducir el sobreajuste. El modelo utiliza la función de pérdida *CrossEntropyLoss* y el optimizador *Adam* con tasa de aprendizaje de 0.001. Tomando para su desarrollo un batch de 32 y 20 épocas, notando que el modelo converge a partir de la época 18.

Durante la etapa de entrenamiento se destinó el 20% del dataset para el proceso de validación con ajuste de hiperparámetros. Algunos de los hiperparámetros ajustados fueron: *dropout*, se incluyeron transformaciones adicionales (data augmentation), ajuste de los pesos del modelo para controlar el sobreajuste a través de *weight_decay* y la implementación de la reducción de la tasa de aprendizaje por medio de *scheduler*. Los ajustes descritos se hicieron revisando las métricas de pérdida del modelo, precisión y matrices de confusión.

Igualmente como se mencionó previamente, se realizó

una aproximación experimental adicional, en la cual se utilizó el modelo *Resnet 18* bajo el framework MONAI. Este modelo mantiene en su desarrollo la misma estructura y parámetros del modelo *from scratch*.

3. Resultados

Para la generación de los resultados finales se utilizó un conjunto de evaluación (*Test set*), correspondiente al 10% del total de los datos. El modelo alcanzó una precisión general (accuracy) del **92.3%**, el cual es considerado adecuado y consistente con los requerimientos del tipo de aplicación clínica para la cual fue desarrollado.

En la tabla 1 se presentan los resultados de los indicadores de precisión, recall y F1 para cada una de las clases del modelo *from scratch*:

Tabla 1. Comparación de resultados de los modelos *from scratch* (1) y fundacional (2) utilizando el set de datos de prueba (Test)

	Clases vs. Resultados	Glioma	Meningioma	Pituitary	Paciente Sano
1	**Precisión**	0.96	0.86	0.92	0.96
	Recall	0.84	0.87	0.98	0.99
	F1 - score	0.89	0.86	0.95	0.97
2	**Precisión**	0.98	0.74	0.99	0.98
	Recall	0.84	0.98	0.92	0.89
	F1 - score	0.90	0.84	0.95	0.93

Así mismo en la figura 2 se puede observar la matriz de confusión sobre el conjunto de datos de prueba (*Test set*).

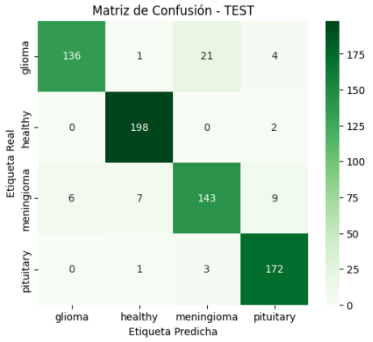

Fig 2 Matriz de confusión para el conjunto de datos de prueba (*Test set*).

Se destaca dentro de los resultados la alta sensibilidad (*recall*) en la clasificación de los pacientes sanos, con un porcentaje de falsos negativos del 1.2%. Así mismo, las métricas de *F1-score* para las clases *Pituitary* y *Paciente sano* superan el 95%, evidenciando un equilibrio entre la detección de verdaderos positivos y la reducción de falsas clasificaciones.

Comparando los modelos, encontramos que el entrenamiento del modelo desde cero es mucho más rápido, debido a su baja profundidad, permitiendo realizar un fácil ajuste de hiperparámetros. En contraste, el modelo fundacional presenta un alto consumo computacional, por lo que su ajuste se vio limitado. Concluyendo que este modelo presenta una gran oportunidad de mejora a futuro.

4. Discusión

Para el modelo *from scratch*, la clase que presenta las métricas más bajas es meningioma. El modelo confunde 21 pacientes con glioma, clasificándolos erróneamente como meningioma. Esta confusión puede obedecer principalmente al tipo de patología, ya que ambos tumores pueden presentar intensidades y patrones de textura similares en secuencias T1 o T2, especialmente en cortes cercanos a la superficie cerebral; adicionalmente, las limitaciones de una arquitectura basada en **AlexNet**, la cual, si bien es potente, posee una profundidad reducida que limita su capacidad para captar texturas finas.

Por este motivo, realizamos la comparación de estos resultados con el del modelo fundacional (*ResNet 18 MONAI*) según lo mencionamos. En la aproximación experimental desarrollada, utilizando el mismo dataset obtuvimos una precisión general de **90.6%.** En la tabla 1 se observan los resultados de los principales indicadores para este modelo.

A partir de los resultados presentados podemos concluir que el modelo *from scratch* permite una acertada predicción de pacientes sanos maximizando los verdaderos positivos de esta clase. De otro lado, este modelo presenta una limitación en la clasificación del tipo de cáncer (especialmente entre gliomas y meningiomas), lo cual hace que este modelo pueda ser utilizado para primeras fases de diagnóstico binario (paciente sano vs. paciente con cáncer)

El modelo fundacional presenta una alta precisión en las clases *glioma*, *pituitary* y *paciente sano* y sus métricas para las clases glioma y pituitary son mejores que el primer modelo evaluado; sin embargo, presentó un sobreajuste sobre la clase *meningioma*, el cual puede ser superado mediante el ajuste de los hiperparametros de *dropout*, L2 y *early stopping*, tal como fue realizado con el modelo *from scratch*. Ajustes, que como ya mencionamos no fue posible realizar por limitaciones computacionales.

En conclusión, los modelos entrenados *from scratch* resultan adecuados para tareas generales, ya que su bajo consumo computacional permite un ajuste flexible y rápido según las necesidades del proyecto. Por otro lado, los modelos fundacionales son más apropiados para aplicaciones especializadas, al contar con el respaldo de comunidades científicas y de investigación que han optimizado su desempeño en la interpretación de imágenes radiológicas.

Referencias

[1] Project MONAI, "MONAI: Medical Open Network for AI, version 1.5.0," *Zenodo*, Jun. 14, 2025. [Online]. Available: https://github.com/Project-MONAI/MONAI

[2] [2] M. Nickparvar, "Brain Tumor MRI Dataset," *Kaggle*, 2022. [Online]. Available: https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset