Clasificación Multi-Etiqueta de Artículos de Noticias de la BBC usando Transformers

Diego Burbano Omar Diaz

1. Introducción

En 2021 se generaron más de 857 mil artículos de noticias por día en medios digitales a nivel global [1], y esta cifra continúa aumentando, lo que produce un volumen masivo de información que debe ser organizado y clasificado para facilitar su consumo. Este crecimiento plantea un reto tanto para los usuarios, que requieren contenidos alineados a sus intereses, como para los medios, que necesitan distribuir eficientemente la información.

En este contexto, las técnicas de *Deep Learning* se han consolidado como herramientas clave para la clasificación automática de texto, gracias a su capacidad para capturar patrones semánticos y contextuales en el lenguaje. Actualmente, el estado del arte está dominado por los Transformers, que representan el estándar industrial y académico por su rendimiento y capacidad de generalización. Paralelamente, ha surgido una tendencia hacia modelos más compactos y eficientes, diseñados para reducir costos computacionales sin sacrificar desempeño.

Estudios previos han destacado el papel de los modelos de lenguaje pre-entrenados (PLM), como NewsBERT [2], específicamente diseñados para tareas de clasificación de noticias. En este trabajo se emplea DistilBERT, una versión ligera de BERT, para realizar clasificación multiclase sobre el conjunto de datos público BBC News. El objetivo es evaluar su desempeño y compararlo con variantes del modelo BERT, como RoBERTa y ALBERT, analizando sus diferencias en eficiencia y precisión.

2. Metodología

Para el desarrollo y ajuste del modelo DistilBERT, se utilizó el set de datos BBC Articles Dataset [3] el cual contiene más de 2100 artículos de noticias publicados por la BBC, organizados en cinco (5) categorías temáticas como *business, tech, politics, sport* y *entertainment,* del sitio kaggle.com. Este conjunto de datos fue procesado, realizando codificación de las etiquetas, limpieza de texto y finalmente tokenización, a fin de contar con un set de datos compatible con el modelo pre-entrenado. Considerando que el texto a clasificar trae en promedio entre 50 y 150 tokens, se definió en 70 la máxima longitud del token, lo que permite un balance entre capacidad de computo y eficiencia, minimizando el *padding,* a fin de asegurar mayor capacidad de generalización.

Para el entrenamiento y posterior validación y prueba de los modelos se dividió el set de datos en 80% para entrenamiento, 10% para validación y 10% para pruebas.

La arquitectura consiste en un modelo pre-entrenado DistilBERT, el cual ya cuenta con pesos pre-entrenados, cuenta con capacidad de tokenizar según BERT y comprende relaciones sintácticas y semánticas en inglés. Adicionalmente, a fin de asegurar la capacidad de clasificación, se agregaron un *pooler* sobre la representación y una capa *feedforward* final con 5 salidas. En la Fig. 1, se aprecia el detalle de la arquitectura diseñada.

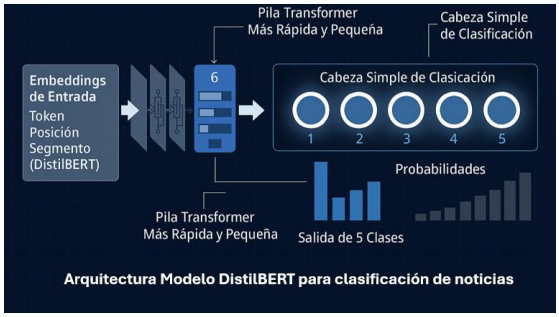

Fig. 1. Representación de la arquitectura general del modelo DistilBERT.

Se seleccionaron hiper parámetros estándar para el fine-tuning de modelos *Transformer*, priorizando estabilidad de entrenamiento y prevención de overfitting. Se utilizó un *learning rate* bajo (2e-5) para evitar modificar agresivamente los pesos pre-entrenados. El número de *epochs* (3) corresponde al valor típico para modelos como BERT y DistilBERT en *datasets* de tamaño medio. El *batch size* de 8 equilibra estabilidad numérica y limitaciones de memoria GPU. Se empleó *weight decay* de 0.01 para controlar la complejidad del modelo y mejorar la generalización. Finalmente, tanto la evaluación como los *checkpoints* se ejecutan al final de cada *epoch*, y se habilitó *load_best_model_at_end* para asegurar que el modelo final corresponda al mejor desempeño observado en validación.

3. Resultados

Para la generación de resultados finales, se utilizó un conjunto de datos de pruebas (*test*) el cual representa el 10% de los datos totales utilizados. En la Fig. 2 se aprecia

la matriz de confusión generada.

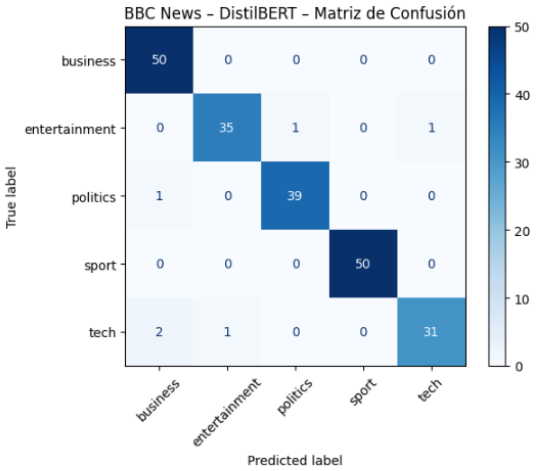

Fig. 2. Matriz de Confusión para el modelo DistilBERT.

El *accuracy* promedio para este conjunto de datos fue del 93%, la precisión 94%, el *recall* 94% y el *F1-score* del 94%. Se deduce que el modelo presenta una capacidad de generalización adecuada para clasificación. El resto de las métricas confirma que el modelo presenta un desempeño apropiado comparando con alternativas de variaciones de modelos BERT como RoBERTa y ALBERT [4]. Dicho estudio analiza modelos derivados de BERT mediante *fine-tuning* supervisado en clasificación multiclase. La Tabla 1 presenta la comparación entre los dos modelos.

Model / Metric	Precision	Recall	F1-Score
DistilBERT	94%	94%	94%
BERT [4]	74%	73%	73%
RoBERTa [4]	74%	74%	74%
ALBERT[4]	73%	72%	72%

Tabla 1. Comparación de resultados entre modelos basados en BERT.

Si bien los estudios presentan similitudes como las ya citadas, debe señalarse que los datos utilizados difieren en origen y estructura, lo cual influye en los resultados. Es importante considerar que DistilBERT fue sometido a un proceso de *fine-tuning* intensivo, lo que contribuyó a su rendimiento.

El modelo demuestra una fuerte capacidad para capturar relaciones semánticas entre tokens, lo que se refleja en una clasificación precisa. Sin embargo, al reducir max_sequence_length, el modelo pierde contexto y disminuye su capacidad discriminativa. Al pasar de 70 a solo 5 tokens, confunde categorías —por ejemplo, "legendary dutch boss" y "gb quartet get…" son predichas como entertainment en lugar de sports— y su accuracy cae al 75%. En consecuencia, 70 tokens ofrecen mayor precisión al preservar más contexto, mientras que 5 tokens reducen el costo computacional a costa de degradar la calidad predictiva como se aprecia en la Fig. 3.

Fig. 3. Comparación función de perdida con el conjunto de inferencia.

4. Discusión

Los resultados obtenidos muestran que la nueva tendencia de arquitecturas *Transformers* han permitido democratizar el uso de modelos fundacionales, eliminando barreras en su uso, para diferentes aplicaciones, acelerando la obtención de resultados con un moderado costo computacional.

Estos resultados se obtuvieron usando un número conservador de tokens, adecuado para textos periodísticos, donde la mayor parte del contexto semántico suele concentrarse en las primeras palabras. No obstante, no todos los textos presentan esta estructura; en esos casos sería necesario incrementar max_sequence_length para mantener el rendimiento. La arquitectura propuesta resulta apropiada para tareas como análisis de sentimientos o clasificación en redes sociales. En contraste, dominios donde la información relevante está distribuida a lo largo del documento —como análisis legal, científico, opinión extendida o sistemas de pregunta-respuesta sobre textos extensos— requieren un tratamiento adicional, incluyendo mayor capacidad de cómputo y ajustes de secuencia, para obtener resultados satisfactorios

Estos hallazgos refuerzan el potencial de modelos ligeros como DistilBERT para aplicaciones reales, acercando el poder de la IA a contextos donde antes era inviable por costo o complejidad.

Un reto adicional consiste en aplicar este mismo tipo de iniciativas para modelos que extiendan su uso a ámbitos más complejos sin depender del lenguaje tales como imágenes o videos con VLMs como se discute en [5] ("*The Shape of AI to Come!*"), donde se expone como superar la limitación del lenguaje de los LLM con enfoques de arquitectura espacial (*Modelo JEPA – Joint Embedding Predictive Architecture)*, los cuales pretenden predecir porciones de imágenes reconstruyendo un "modelo del mundo", lo cual es esencial para la robótica y los agentes autónomos.

Referencias

[1] NewsCatcher, “How many news articles are published per day?,” NewsCatcher Blog, 2021, updated 2023. [Online]. Available: https://newscatcherapi.com/blog/how-many-news-articles-are-published-every-day.

[2] C. Wu, F. Wu, Y. Yu, T. Qi, Y. Huang, and Q. Liu, "NewsBERT: Distilling Pre-trained Language Model for Intelligent News Application," in Findings of the Association for Computational Linguistics: EMNLP 2021, pp. 3285–3295, Nov. 2021.

[3] J. Ferretti, "BBC Articles Dataset," Kaggle, 2021. [Online]. Available: https://www.kaggle.com/datasets/jacopoferretti/bbc-articles-dataset.

[4] C. Y. Sy, L. L. Maceda, M. J. P. Canon, and N. M. Flores, "Beyond BERT: Exploring the Efficacy of RoBERTa and ALBERT in Supervised Multiclass Text Classification," International Journal of Advanced Computer Science and Applications (IJACSA), vol. 15, no. 3, pp. 223–230, 2024. [Online]. Available: https://www.ijacsa.thesai.org

[5] DSAI by Dr. Osbert Tay, "The Shape of AI to Come! Yann LeCun at AI Action Summit 2025," YouTube, 2025. [Online]. Available: https://www.youtube.com/watch?v=xnFmnU0Pp-8